

© 2025 г. М.Ю.ЛАЗУТОВ (marklazutov@gmail.com),
(Университет ИТМО, Санкт-Петербург)
В.Н.ЛЕОНЕНКО, канд.физ.-мат. наук (vnleonenko@yandex.ru)
(Университет ИТМО, Санкт-Петербург;
НИИ гриппа им. А. А. Смородинцева, Санкт-Петербург)

ПРОГНОЗИРОВАНИЕ ЭПИДЕМИЙ ОСТРЫХ РЕСПИРАТОРНЫХ ИНФЕКЦИЙ С ИСПОЛЬЗОВАНИЕМ СИГНАЛОВ РАННЕГО ПРЕДУПРЕЖДЕНИЯ И МОДЕЛЕЙ МАШИННОГО ОБУЧЕНИЯ ¹

Прогнозирование критических переходов в динамике заболеваемости эпидемическими инфекциями — важнейшая задача эпидемиологического надзора, влияющая на эффективность работы системы здравоохранения. В данном исследовании рассматривается использование методов детекции аномалий во временных рядах заболеваемости на основе искусственного интеллекта и сигналов раннего предупреждения (СРП) для предсказания моментов перехода от сезонных инфекций к эпидемическим вспышкам. Рассматриваются два основных подхода: метод на основе классификации, определяющий близость к критическому переходу, и метод на основе регрессии для прогнозирования будущей динамики инфекции. Различные модели машинного обучения, включая ансамблевые методы (Easy Ensemble, RUSBoost, Balanced Bagging), архитектуры глубокого обучения (Early Warning Signal Network (EWSNet), LSTM, GRU), применяются к данным двух типов: заболеваемости гриппом с маркировкой временных отрезков, соответствующих эпидемическим периодам согласно экспертным критериям, и заболеваемости COVID-19 без маркировки. Результаты показывают, что Easy Ensemble и EWSNet обеспечивают наилучший баланс между значениями метрик precision и recall. Рекуррентные нейронные сети эффективно моделируют динамику средних значений, но прогнозирование дисперсии показателей остается сложной задачей. Приведённые в статье результаты демонстрируют потенциал сочетания классических методов СРП с машинным обучением для улучшения прогнозирования эпидемий и поддержки принятия решений в здравоохранении.

Ключевые слова: прогнозирование эпидемий, сигналы раннего предупреждения, машинное обучение, анализ временных рядов, критические переходы.

¹Работа выполнена при финансовой поддержке Российского научного фонда в соответствии с Соглашением № 24-25-20104 от 12.04.2024 г. и Санкт-Петербургского государственного автономного учреждения “Фонд поддержки научной, научно-технической, инновационной деятельности” о предоставлении регионального гранта для софинансирования проекта в рамках соглашения № 24-25-20104 от 22.05.2024 г. от 03.06.2024 г. № 169.

1. Введение

Задача раннего обнаружения и прогнозирования критических явлений в сложных системах является актуальной проблемой для многих научных областей [1], в том числе для эпидемиологии [2]. Её можно также рассматривать как частный случай более общей темы распознавания совокупности сигналов из заданного ансамбля [3] — например, в контексте появления циркулирующих штаммов респираторных инфекций нового типа, которые мало отличимы от сезонных ОРВИ в общей собираемой статистике эпиднадзора. В силу важности проблематики, для детектирования критических явлений и моментов смены состояний в сложных системах наряду с более общими методами разрабатываются специальные статистические методы и индикаторы. В частности, близость к точке перехода между состояниями (критической точке) можно определить расчётом так называемых сигналов раннего предупреждения (СРП, в англоязычной литературе — Early Warning Signals, EWS). К настоящему моменту разработано большое количество вариантов СРП — например, спектральные СРП (основанные на расчете спектра временного ряда) или СРП, основанные на явлении критического замедления [4]. К последним относятся, например, методы, детектирующие увеличение дисперсии, автокорреляционной функции, перекоса (skew) и т.д. В контексте эпидемических процессов, на которые делается акцент в данной работе, существует достаточно много исследований, посвященных анализу использования СРП как на синтетических, так и на реальных данных [5].

Целью настоящего исследования является сравнительный анализ методов раннего детектирования всплесков заболеваемости, связанных с пандемическими ОРВИ, на данных заболеваемости ОРВИ, включая сезонный грипп и COVID-19. Важной задачей является сравнение специализированных СРП на основе явления критического замедления (critical slowing down) с более общими статистическими подходами и оценка их эффективности для задач управления и контроля эпидпроцессов. Рассмотрены два варианта решения задачи прогнозирования критических явлений на основе СРП: на данных с обозначенным эпидемическим порогом и без него. В данных, содержащих уровень эпидемического порога, возможна постановка задачи бинарной классификации: критическая точка перехода либо «близка», либо нет (близость выбирается исходя из требований эпиднадзора — например, один месяц до критической точки). В противном случае, когда маркировка эпидпорогов отсутствует (как в случае рассмотрения COVID-19, где с момента появления заболевания прошло недостаточно времени, чтобы оценить многолетний базовый уровень), задачу детектирования эпидвсплесков предлагается решать сведением к задаче прогнозирования динамики выбранных СРП (предсказание абсолютных показателей индикаторов), с оценкой времени до критической точки на основе прогнозной заболеваемости. Такой метод можно считать частным случаем использования предсказательных статистических методов многолетней заболеваемости (см., например, [26]), которые наряду с SIR-моделями являются одним из самых популярных видов прогностических моделей в эпидемиологии.

2. История проблемы и современные подходы

Прогнозирование эпидемий с использованием методов машинного обучения в настоящее время активно развивается, следуя общим тенденциям развития технологий

машинного обучения и искусственного интеллекта. Это обусловлено тем, что традиционные методы моделирования (SIR, SEIR и т.д.) часто недостаточно гибки для учета нелинейных факторов и мало подходят для анализа заболеваемости на ранних стадиях пандемии вирусов нового типа [2]. Как подчеркивается в [6], классические алгоритмы машинного обучения (в частности, Random Forest, Support vector machine) демонстрируют высокую эффективность в задачах раннего обнаружения вспышек эпидемий. Кроме того, во многих публикуемых исследованиях (см., например, [7]), относящихся к теме прогнозирования заболеваний, демонстрируется эффективное применение рекуррентных сетей. В то же время в научных группах не пропадает интерес к направлению, относящемуся к теории сложных систем и фокусирующемуся на использовании сигналов раннего предупреждения — задаваемых как статистическими индикаторами, так и объясняющими моделями (например, индекс риска, зависящий от действующих мер социального дистанцирования в популяции [28]). В таблице 1 приведен список работ, использующих различные подходы прогнозирования эпидемий на базе СРП. В некоторых из указанных исследований применяется гибридный подход к прогнозированию, т.е. совместное использование методов машинного обучения и СРП. Несмотря на значительный прогресс в области прогнозирования эпидемий с использованием СРП, наблюдается недостаток исследований со сравнительным анализом эффективности методов машинного обучения в комбинации с СРП. Для восполнения данного пробела в текущем исследовании рассматривается применение гибридного подхода с использованием разных моделей и двух вариантов постановки задачи (классификация и регрессия).

Таблица 1. Список аналогичных работ

	2025 Zhao et al. [8]	2024 Bizzotto et al. [9]	2025 Gao et al. [10]	2024 Drake et al. [11]	2021 O'Brien [12]
Контекст	31 болезнь, 134 региона	COVID-19, Италия	COVID-19, Сингапур, Канада, Гон-Конг	SARS-CoV-2, UK	COVID-19, 24 страны
Метод	Critical-slowing-down resilience indicators + time-to-event analysis	Nowcasting reproduction number method (R_e)	Feature-based time-series classification (ML)	Phylogenetic logistic growth rate (LGR) analysis	Sequential EWS assessment using GAMs
Наиболее результативные СРП	Дисперсия, АКФ	Nowcasted R_e	Дисперсия, АКФ, коэффициент асимметрии	Maximum LGR of dominant clusters	Конкатенация дисперсии, АКФ, коэффициента асимметрии
Горизонт прогнозирования	18–21 дней	6–23 дней	14 дней	6–7 дней	10–14 дней

3. Данные

В настоящем исследовании было использовано два массива входных данных. Первый массив данных был получен из базы данных НИИ гриппа и содержит недельную заболеваемость ОРВИ в г. Санкт-Петербурге за период с января 1990 года по октябрь 2020 года включительно. Помимо абсолютного числа случаев заболевших, массив содержит расчётную численность населения города на рассматриваемый период с шагом в один год, что позволяет пересчитать заболеваемость в относительные показатели, а также индикатор превышения сезонного эпидпорога по методике расчёта НИИ гриппа, что позволяет различать отрезки данных, соответствующие официально объявленной эпидемической ситуации. Общий вид временного ряда представлен на рисунке 1. Исходя из наличия меток в данных, разделяющих заболеваемость на эпидемическую и неэпидемическую (сезонные простуды, не связанные с эпидемией), целесообразно решить задачу классификации на основе СРП.




Рис. 1. Временной ряд с отмеченными эпидемиями

Второй временной ряд был получен с использованием открытых данных по заболеваемости COVID-19 в Санкт-Петербурге за период с марта 2020 по март 2024 года [13]. Общий вид временного ряда показан на рисунке 2. Данные заболеваемости собирались ежедневно. Дать определение «эпидемической вспышке» в контексте COVID-19 сложнее, чем в случае сезонного и пандемического гриппа в силу отсутствия чётко выраженной сезонности для коронавирусной инфекции. В настоящем исследовании мы полагаем вспышками выделяемые в данных продолжительные подъёмы заболеваемости с последующим спадом (эпидемические волны), связанные с появлением новых коронавирусных штаммов.




Рис. 2. Временной ряд без отмеченных эпидемий

4. Теоретические сведения

Для работы с эпидемическими временными рядами среди всевозможных СРП были выбраны индикаторы с наилучшими показателями эффективности в данной предметной области. Исходя из данных в приведённой выше таблице 1, а также из источника [14], наиболее распространенным горизонтом прогнозирования является около 1-2 недель, а наиболее подходящими характеристиками для определения близости к критической точке оказались дисперсия и среднее значение, которые демонстрировали устойчивое повышение при приближении к моменту эпидемического старта. Примеры расчётов значений СРП в двух случаях (вблизи и вдали от точки старта эпидемии гриппа) для временного ряда заболеваемости ОРВИ показаны на рисунке 3. Как видно по графикам, в данном примере наиболее информативным показателем можно считать дисперсию с окном, равным 30: значение показателя в первом случае монотонно возрастает (признак эффекта критического замедления, которое может служить индикацией скорого фазового перехода [4]), а во втором – монотонно убывает (эффекта нет), что соответствует корректному поведению СРП. Дисперсии с окнами 15 и 20 не демонстрируют аналогичное поведение, что говорит о чувствительности показателя дисперсии к выбору окна и, следовательно, необходимостью эмпирического подбора параметра окна перед применением в практике эпиднадзора. В настоящей работе для задачи классификации было решено оценить сравнительную эффективность в роли СРП дисперсии и коэффициента асимметрии, а в задачах регрессии прогнозировать дисперсию и среднее значения заболеваемости для предсказания с их помощью эпидемических подъёмов. В качестве горизонта принятия решения выбраны увеличенные по сравнению с работами из обзора временные диапазоны — 4 и 5 недель для классификации, 14 и 28 дней для регрессии.

В следующем разделе описаны методы, на основе которых решались задачи классификации и регрессии. Для расчёта СРП использовался пакет `ewstools` [15] языка программирования Python.




Рис. 3. СРП вблизи (верхний ряд) и вдали (нижний ряд) от критического перехода

4.1. Классификационный подход

Для решения поставленной задачи был выполнен ряд шагов по предобработке данных для обучения и тестирования моделей. Во-первых, временной ряд был разбит на сегменты без эпидемий, во-вторых — установлен временной интервал t до момента наступления эпидемии, который определяет срок прогноза о приближении эпидемии. Далее была сформирована выборка для обучения.

Предобработка данных происходила следующим образом. Временной ряд с численностью случаев заболеваемости задается в виде вектора $X = \{x_k\}$, $k = \overline{1, |X|}$ и дополняется временным рядом бинарных меток Y :

$$(1) \quad Y = \begin{cases} 1, & \text{epidemic} \\ 0, & \text{no epidemic} \end{cases}$$

Выделяются все сегменты без эпидемии:

$X' = \{X_i | \forall j \in [0, |X_i| - 1] Y_j = 0\}$, $i = \overline{0, M - 1}$, где X_i — подмножество X , M — число сегментов без эпидемии.

Далее полученные сегменты преобразовываются по правилу скользящего окна:

$$(2) \quad X'' = \begin{pmatrix} X_0^{(0)} & X_0^{(1)} & \cdots & X_0^{(w-1)} \\ X_0^{(1)} & X_0^{(2)} & \cdots & X_0^{(w)} \\ \vdots & \vdots & \ddots & \vdots \\ X_{M-1}^{N-w} & X_{M-1}^{N-w+1} & \cdots & X_{M-1}^{N-1} \end{pmatrix},$$

где $N = |X_{M-1}|$, w — размер окна. В настоящем исследовании предполагалось $w = 30$.

Важным вопросом является определение порогового значения t , при достижении которого модель должна сообщать о приближающейся эпидемии. Согласно постановке задачи исследования со стороны специалистов эпидемического надзора, оповещение желательно получать не позже чем за месяц до эпидемического старта, что

соответствует $t=4$ или $t=5$. Поскольку данные во временном ряду по заболеваемости сезонным ОРВИ даются с шагом в одну неделю, $t=4$ и $t=5$ соответствуют интервалам времени в 28 и 35 дней. Был задан следующий бинарный массив, характеризующий близость данной точки временного ряда к эпидемическому старту:

$$(3) \quad Y'_l = \begin{cases} 1, & \text{if } E_l - I_l \leq t \\ 0, & \text{otherwise} \end{cases}$$

где $l = \overline{0, K}$, K — число строк в матрице X'' , I_l — индекс последнего элемента l -го временного ряда в X'' , E_l — первый индекс значения заболеваемости ближайшей эпидемии ($E_l \in [0, |X|]$), соответствующей рассматриваемому временному ряду.

Далее для каждой строки в полученной матрице необходимо рассчитать СРП с определенными значениями окна w_{ews} . В данной работе было решено рассчитать дисперсию при $w_{ews} = \{15, 20, 30\}$ и коэффициент асимметрии при $w_{ews} = 20$. Затем необходимо объединить рассчитанные значения СРП и составить итоговую матрицу:

$$(4) \quad X''' = \begin{pmatrix} S_0^{(0)} & S_0^{(1)} & \dots & V_0'^{(0)} & V_0'^{(1)} & \dots & V_0''^{(0)} & \dots & V_0'''^{(29)} \\ & \vdots & \ddots & & & & \vdots & & \\ S_{M-1}^{(0)} & S_{M-1}^{(1)} & \dots & V_{M-1}'^{(0)} & V_{M-1}'^{(1)} & \dots & V_{M-1}''^{(0)} & \dots & V_{M-1}'''^{(29)} \end{pmatrix},$$

где $S_i^{(j)}$ — значение из массива коэффициентов асимметрии с индексом j , соответствующее временному ряду i ; $V_i'^{(j)}$ — значение из массива дисперсий с $w_{ews} = 15$ и индексом j , соответствующее временному ряду i ; $V_i''^{(j)}$, $V_i'''^{(j)}$ — также значения дисперсий, но с $w_{ews} = 20$ и $w_{ews} = 30$ соответственно.

Таким образом, получаем итоговый массив данных:

$$(5) \quad D_c = \{X_i''', Y_i'\}, \quad i = \overline{1, K}.$$

Полученный набор данных необходимо разделить на обучающую, валидационную и тестовую выборки. В данной работе было принято решение разделить их в пропорции 70%, 10% и 20% соответственно. Элементы выборок не должны смешиваться, поскольку мы работаем с упорядоченными данными временных рядов. Следует отметить, что полученный набор данных несбалансирован, поскольку выборок из класса 0 больше, чем из класса 1 для всех значений t . Поскольку в данной задаче гораздо важнее минимизировать количество ложноотрицательных результатов (неверных предположений об отсутствии угрозы эпидемии). В связи с этим играет первостепенную роль метрика полноты (recall):

$$(6) \quad Recall = \frac{TP}{TP + FN},$$

где TP — доля истинно положительных результатов, FN — доля ложноотрицательных результатов. Необходимо поддерживать адекватное значение точности, т.е. выше 0,5, чтобы убедиться, что модели не классифицируются случайным образом:

$$(7) \quad Accuracy = \frac{TP + TN}{TP + TN + FN + FP},$$

где FP — доля ложноотрицательных результатов, TN — доля истинно отрицательных результатов. Также важно измерять баланс между FN и FP, поэтому следует использовать, например, оценку F1:

$$(8) \quad F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}.$$

Площадь под PR-кривой (PR-AUC) также может быть полезной метрикой для оценки моделей, поскольку она не зависит от количества истинно отрицательных результатов. Кроме того, она суммирует эффективность модели в диапазоне пороговых значений, поэтому может быть более информативной, чем оценка F1.

Для классификации использовались следующие модели: EWSNet, Easy Ensemble [18], RUSBoost [19], Balanced bagging classifier [20], Decision Tree и Random Forest [21]. При наличии большого количества данных для обучения использование глубоких нейронных сетей с конволюционными и рекуррентными слоями оказывается очень эффективным для классификации предстоящих критических точек перехода [16, 17]. Поэтому в контексте эпидемических временных рядов на фоне более универсальных методов было решено также протестировать более специализированный метод EWSNet [17]. Эта модель представляет собой комбинацию двух независимо работающих сетей: сети с долговременной и кратковременной памятью (LSTM) и полностью сверточной сети (FCNN). Авторы обучили EWSNet на большом синтетическом наборе данных, состоящем из динамики показателей нескольких динамических систем. Модель демонстрирует хорошую точность на эмпирических тестовых данных, но не лишена проблемы частых ложных срабатываний. Точность модели на тестовых данных из упомянутой статьи составила около 75%. Её главное преимущество по сравнению с классическими моделями машинного обучения — инвариантность к длине входящих временных рядов. Результаты сравнения эффективности указанных методов приведены в следующем разделе.

4.2. Регрессионный подход

Для постановки задачи предсказания эпидемического подъёма заболеваемости COVID-19 по немаркированным данным временной ряд доли положительных тестов на COVID-19 был представлен как массив $X = \{x_k\}$, $k=1, |X|$. В данном случае было решено разделить временной ряд в соотношении 70% на обучающий набор, 10% на валидационный (проверочный) набор и 20% на тестовый набор.

Пусть $T = \lceil 0.7 \cdot |X| \rceil$ and $V = \lceil 0.1 \cdot |X| \rceil$, тогда:

$$(9) \quad X_{train} = \{x_k\}, \quad k = \overline{1, T},$$

$$(10) \quad X_{val} = \{x_k\}, \quad k = \overline{T+1, T+V},$$

$$(11) \quad X_{test} = X \setminus (X_{train} \cup X_{val}).$$

Мы можем вычислить множество СРП, т.е. дополнительных временных рядов, в скользящем окне $w_{ews} = 14$. Таким образом, каждая точка x_k множества X сопоставляется точке e_X^k временного ряда СРП E_X , вычисляемого внутри отрезка $[x_{k-w_{ews}}, x_{k-1}]$. Тогда задача моделирования формулируется как вычисление

$\{e_X^{T+V+1}, e_X^{T+V+2}, \dots\}$. В этой задаче было решено ограничиться рядом средних значений $E_{X_{mean}}$ и рядом дисперсий $E_{X_{var}}$.

Для обучения моделей полученные ряды необходимо преобразовать в матрицы с использованием некоторого скользящего окна m . Этот параметр можно определить, оценив метрики на проверочной выборке. Информация о метриках приведена ниже.

Для оценки качества моделирования мы будем использовать пять метрик. Это MSE, RMSE, MAE, NRMSE, NMAE, R^2 :

$$(12) \quad MSE = \frac{1}{|X_{test}|} \sum_{k=1}^{|X_{test}|} (e_X^{T+V+k} - x_{T+V+k})^2,$$

$$(13) \quad RMSE = \sqrt{MSE},$$

$$(14) \quad MAE = \frac{1}{|X_{test}|} \sum_{k=1}^{|X_{test}|} |e_X^{T+V+k} - x_{T+V+k}|,$$

$$(15) \quad NRMSE = \frac{RMSE}{\max(X_{test}) - \min(X_{test})},$$

$$(16) \quad NMAE = \frac{MAE}{\max(X_{test}) - \min(X_{test})},$$

$$(17) \quad R^2 = 1 - \frac{\sum_k (x_{T+V+k} - e_X^{T+V+k})^2}{\sum_k (x_{T+V+k} - \text{mean}(X_{test}))^2}.$$

В качестве функции потерь в моделях был выбран показатель MSE, при этом также производился расчёт MAE, так как данный показатель лучше подходит для интерпретации величины отклонения с точки зрения предметной области. RMSE — более строгая метрика, поскольку она более чувствительна к выбросам, чем MAE. Поскольку в исследовании анализировались ряды с разными масштабами (средне и дисперсия), было решено использовать нормализованные метрики, такие как NRMSE и NMAE, поскольку они инвариантны к изменению масштаба. Для определения величины линейной корреляции между истинными и прогнозируемыми значениями применялся коэффициент детерминации R^2 .

Во многих работах авторы применяют резервуарные вычисления для выполнения краткосрочного прогноза [22, 23, 24]. Прогноз является краткосрочным, поскольку авторы обучают модели только на сегментах, где нет критических переходов. В противном случае моделирование динамики некорректно. Так, например, в [30] авторы попытались использовать рекуррентные нейронные сети для прогнозирования критических переходов в экологических системах. Для обучения сетей использовались «сырые» временные ряды, т.е. без использования СРП, и не всем моделям удалось сформировать корректную оценку. Однако в нашем случае имеется информация о

некоторых произошедших критических переходах, которая может быть использована для моделирования долгосрочного прогноза. Поэтому было решено использовать сеть LSTM, а также GRU, которая является упрощённой версией LSTM (в ячейке этой сети на один элемент меньше). Стоит отметить, что LSTM-сети считаются наиболее устойчивыми и точными для прогнозирования хаотических динамических систем [31]. В экспериментах использовались LSTM и GRU-сети со 128 ячейками, выбранная ширина скользящего окна m равна 20, то есть 20 дней (или 20 входных нейронов). Во всех случаях было решено задать 100 эпох и использовать оптимизатор ADAM.

5. Результаты экспериментов

5.1. Результаты классификации

В таблицах 2 и 3 представлены результаты вычисления метрик на тестовом множестве на основе оптимальных гиперпараметров для значений порога $t=4$ и $t=5$ соответственно. Аналогичным образом были рассчитаны матрицы ошибок (рисунок 4).

Таблица 2. Результаты вычисления метрик для временного горизонта в четыре недели ($t=4$)

Классификатор	Accuracy	Recall	F1 score	PR-AUC
Decision Tree	0.79	0.55	0.65	0.75
Easy Ensemble	0.72	0.93	0.70	0.87
RUSBoost	0.70	0.89	0.67	0.78
Balanced Bagging	0.80	0.89	0.76	0.84
EWSNet	0.71	0.96	0.7	0.86
Random Forest	0.77	0.89	0.73	0.85

Таблица 3. Результаты вычисления метрик для временного горизонта в пять недель ($t=5$)

Classifier	Accuracy	Recall	F1 score	PR-AUC
Decision Tree	0.85	0.78	0.82	0.89
Easy Ensemble	0.78	0.89	0.78	0.92
RUSBoost	0.75	0.90	0.73	0.90
Balanced Bagging	0.77	0.81	0.75	0.86
EWSNet	0.80	0.86	0.80	0.88
Random Forest	0.77	0.81	0.75	0.90




Рис. 4. Матрицы ошибок при $t=4$ (два верхних ряда) и при $t=5$ (два нижних ряда)

По результатам экспериментов можно сделать следующие выводы:

- В случае решающих деревьев (Decision Trees) показатель accuracy меняется от средних до высоких значений (около 0,75–0,85), однако recall и F1 score сильно варьируют в зависимости от порогового значения. Данный метод показывает неудовлетворительные значения recall при низких пороговых значениях времени ($t = 4$). Более низкий PR-AUC по сравнению с другими ансамблевыми методами предполагает более слабую эффективность ранжирования положительных образцов.
- Easy Ensemble стабильно демонстрирует хорошие результаты при разных пороговых значениях полноты, PR-AUC и оценки F1. Методология адаптивного бустинга в сочетании с сэмплингом эффективно справляется с дисбалансом.

Высокие значения показателя полноты указывают на чёткую идентификацию классов с малыми характеризующими выборками, но иногда за счёт несколько более низкой точности (что отражается в не самом высоком значении F1).

- RUSBoost обеспечивает сбалансированные результаты с хорошими значениями recall и PR-AUC. Платой за простоту и надёжность метода в условиях несбалансированных классов является немного более низкая ассигасу при низких пороговых значениях ($t = 4$) по сравнению с Easy Ensemble.
- Метод Balanced Bagging можно считать надёжным инструментом классификации со средними показателями recall, PR-AUC и F1 score. Использование методов оверсэмплинга, таких как SMOTE, при $t=4$ улучшает обнаружение классов с малыми выборками.
- Специализированный метод EWSNet демонстрирует высокие значения recall, но немного уступает по ассигасу и показателю F1 score. Надёжно работает при $t=4$, достигая максимального в эксперименте значения recall в 0,965, но снижение точности ограничивает его конкурентоспособность по показателю F1 score.
- Случайный лес (Random Forest) демонстрирует стабильные результаты при меньшей структурной сложности и сложности использования по сравнению с конкурентами (минимальное количество признаков и деревьев). При этом значение показателя PR-AUC, как правило, отстаёт от ансамблевых методов, таких как Easy Ensemble и RUSBoost.

5.2. Регрессионный подход

Вычисленные метрики на тестовом множестве по заболеваемости COVID-19 (второй временной ряд) для различных горизонтов прогнозирования (14 и 28 дней) представлены в таблице 3 и таблице 4 для сетей GRU и LSTM соответственно. Графическое представление прогнозов приведено на рис. 5.

Таблица 4. Результаты для GRU

	14 дней		28 дней	
	Среднее	Дисперсия	Среднее	Дисперсия
<i>NMAE</i>	0.038	0.058	0.074	0.077
<i>NRMSE</i>	0.057	0.125	0.113	0.139
R^2	0.960	0.697	0.838	0.494

Таблица 5. Результаты для LSTM

	14 дней		28 дней	
	Среднее	Дисперсия	Среднее	Дисперсия
<i>NMAE</i>	0.032	0.063	0.054	0.077
<i>NRMSE</i>	0.055	0.131	0.094	0.123
R^2	0.961	0.652	0.899	0.578




Рис. 5. Результаты предсказания среднего и дисперсии для временного ряда заболеваемости COVID-19

Как видно из таблиц 4 и 5, результаты LSTM лучше, чем у модели GRU, однако разница между ними невелика, что позволяет применять оба подхода. Среднее значение прогнозируется лучше, чем дисперсия. Как и ожидалось, результаты для длинного горизонта прогнозирования (28 дней) хуже, но их по-прежнему можно считать удовлетворительными в случае предсказания средних значений.

6. Заключение

В исследовании рассматриваются методы прогнозирования критических переходов в эпидемических временных рядах с использованием сигналов раннего предупреждения и методов машинного обучения. В исследовании выделены два основных подхода: бинарная классификация для определения близости к критическим точкам перехода и предсказательное моделирование среднего и дисперсии показателей заболеваемости. При внедрении описанных методов в системы эпиднадзора предсказательное моделирование предполагается использовать на ранних стадиях циркуляции пандемических штаммов вирусов нового типа. Когда сезонность изучаемой инфекции не установлена и сложно различать отдельные эпидемические волны, очередной подъём заболеваемости может выводиться непосредственно из интервальных прогнозных оценок, полученных через предсказанные значения среднего и дисперсии числа новых случаев инфекции. После перехода нового заболевания в сезонное,

с выраженными периодами эпидемических подъёмов и спадов, становится возможным оценка пороговой заболеваемости, выделяющая эпидемические волны, и, как следствие, соответствующая маркировка сегментов временных рядов на основе ретроспективных данных. В этом случае предполагается переход к более простым в использовании алгоритмов обнаружения эпидвспышек на основе постановки задачи классификации.

Согласно результатам экспериментов, для решения задачи классификации наиболее эффективными моделями являются Easy Ensemble и EWSNet. Метрики эффективности для этих методов изменяются незначительно при всех рассмотренных пороговых значениях, демонстрируя высокое значение показателя recall и удовлетворительное значение точности (precision). Для решения задач прогноза заболеваемости рекуррентные нейронные сети, включая архитектуры LSTM и GRU, эффективно моделировали динамику среднего значения, но испытывали трудности с предсказанием дисперсии. Дисперсия, будучи по своей природе менее гладкой и более чувствительной к флуктуациям, представляла собой более сложную задачу для этих моделей. Значения метрик NRMSE и R^2 указывают на удовлетворительные предсказательные способности для динамики среднего значения, при этом LSTM немного превосходит GRU.

Данное исследование демонстрирует жизнеспособность сочетания расчёта СРП и использования методов машинного обучения для прогнозирования критических переходов в эпидемических системах. Полученные результаты могут быть использованы не только для здравоохранения, но и для других областей, где понимание и прогнозирование критических явлений имеет большое значение. Продолжение представленной работы предполагается в направлении расширения тестовых наборов данных и изучения усовершенствованных архитектур для повышения надежности и применимости упомянутых методов в других сценариях. В качестве перспективных подходов, могущих улучшить качество раннего детектирования эпидемических вспышек, планируется рассмотреть комбинированные многофакторные подходы машинного обучения, в том числе на основе мультимодальных данных. В частности, модели могут учитывать температурные показатели и влажность [29], число запросов пользователей в поисковых системах, связанных с заболеваемостью [25], а также данные ретроспективной заболеваемости дополнены данными обращений в телемедицинские сервисы с кашлем и посещение отделений неотложной помощи с бронхиолитом [27]. Несмотря на то что внедрение таких подходов в эпиднадзор РФ лимитировано ограниченной доступностью и низким качеством подобных данных, подобные модели могут быть уже сейчас реализованы и протестированы на синтетических данных для будущего их использования по мере улучшения сбора и открытия доступа к новым массивам данных по демографическим и эпидемическим показателям.

СПИСОК ЛИТЕРАТУРЫ

1. *Ramadevi B., Bingi K.* Chaotic time series forecasting approaches using machine learning techniques: A Review // *Symmetry*. 2011. V. 14. No. 955.
2. *Leonenko, V.N.* When a Pandemic Comes to Town: Combating Propagation of Novel Viruses in Russian Cities Using Statistical and Mathematical Modeling // In 2024

IEEE 3rd International Conference on Problems of Informatics, Electronics and Radio Engineering (PIERE) (pp. 990-995). IEEE, 2024, November.

3. *Бульчев, Юрий Гурьевич*. Распознавание сигналов без расширения пространства состояний по результатам наблюдений, содержащих сингулярную помеху, с учетом нелинейности // Автоматика и телемеханика. 2024. № 2. С. 81-102.
4. *Bury T. et al.* Detecting and distinguishing tipping points using spectral early warning signals // Journal of the royal society. 2020. V. 17.
5. *Southall E. et al.* Early warning signals of infectious disease transitions: a review // J.R. Soc. 2021. V. 18. P. 20210555.
6. *Alfred R., Obit J. H.* The roles of machine learning methods in limiting the spread of deadly diseases: A systematic review // Heliyon. 2021. V. 7. No. 6.
7. *Adugna A. et al.* Deep learning architectures for influenza dynamics and treatment optimization: a comprehensive review // Frontiers in Artificial Intelligence. 2025. V. 8. P. 1521886.
8. *Zhao Q. et al.* Early warning signals of emerging infectious diseases // bioRxiv. 2025. Number 2025.03.03.641350.
9. *Bizzotto A. et al.* Increasing situational awareness through nowcasting of the reproduction number // Frontiers in Public Health. 2024. Vol. 12.
10. *Gao S. et al.* Early detection of disease outbreaks and non-outbreaks using incidence data: A framework using feature-based time series classification and machine learning // PLOS Computational Biology. 2025. Vol. 21. Number e1012782.
11. *Drake K. et al.* Phylogenomic early warning signals for SARS-CoV-2 epidemic waves // EBioMedicine. 2024. Number 38194742.
12. *O'Brien et al.* Early warning signals predict emergence of COVID-19 waves // medRxiv. 2021. Number 2021.06.24.21259444.
13. *Kouprianov A.* COVID-19.SPb.monitoring. Monitoring COVID-19 epidemic in St. Petersburg, Russia: Data and scripts. 2021. URL <https://github.com/alexei-kouprianov/COVID-19.SPb.monitoring>.
14. *Brett T. et al.* Detecting critical slowing down in high-dimensional epidemiological systems // PLoS Computational Biology. 2020. V. 16, e1007679.
15. *Bury T.* ewstools: A Python package for early warning signals of bifurcations in time series data // The Journal of Open Source Software. 2022. V. 8.
16. *Bury T. et al.* Deep learning for early warning signals of tipping points // PNAS. 2021. V. 118, e2106140118.
17. *Smita D. et al.* Machine learning methods trained on simple models can predict critical transitions in complex natural systems // Royal Society Open Science. 2022. V. 9. Is. 2.

18. *Liu X.Y. et al.* Exploratory Undersampling for Class-Imbalance Learning // IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics). 2009. V. 39. No. 2.
19. *Seiffert C. et al.* RUSBoost: A hybrid approach to alleviating class imbalance // IEEE Transactions on Systems, Man, and Cybernetics-Part A: Systems and Humans. 2010. V. 40. No. 1.
20. *Maclin R., Opitz D.* An empirical evaluation of bagging and boosting // Proceedings of the Fourteenth National Conference on Artificial Intelligence. 1997. P. 546-551.
21. *Bishop C.* Pattern recognition and machine learning. – Berlin, Germany: Springer. 2006. 778 p.
22. *Deb, S., Sidheekh, S., Clements, C.F., Krishnan, N.C. and Dutta, P.S.* Machine learning methods trained on simple models can predict critical transitions in complex natural systems // Royal Society Open Science. 2022. Vol. 9, No. 2. P.211475.
23. *Lim S. et al.* Predicting Critical Transitions in Multiscale Dynamical Systems Using Reservoir Computing // Chaos. 2020. V. 30. No. 123126.
24. *Kong L.-W. et al.* Machine learning prediction of critical transition and system collapse // Physical Review Research. 2021. V. 3. No. 013090.
25. Su K. et al. Forecasting influenza activity using self-adaptive AI model and multi-source data in Chongqing, China //eBioMedicine. – 2019. – T. 47. – C. 284-292
26. Zhang X. et al. Predicting influenza-like illness trends based on sentinel surveillance data in China from 2011 to 2019: A modelling and comparative study1 //Infectious Disease Modelling. – 2024. – T. 9. – №. 3. – C. 816-827.
27. Morbey R. A. et al. Using machine learning to forecast peak health care service demand in real-time during the 2022–23 winter season: A pilot in England, UK //PloS one. – 2025. – T. 20. – №. 1. – C. e0292829.
28. Cho G. et al. Detection of COVID-19 epidemic outbreak using machine learning //Frontiers in Public Health. – 2023. – T. 11. – C. 1252357.
29. Amendolara A. B. et al. LSTM-based recurrent neural network provides effective short term flu forecasting //BMC Public Health. – 2023. – T. 23. – №. 1. – C. 1788.
30. Lapeyrolerie M., Boettiger C. Limits to ecological forecasting: Estimating uncertainty for critical transitions with deep learning // Methods in Ecology and Evolution. – 2022. – Vol. 14, Is. 3. – P. 785-798.
31. Sangiorgio M., Dercole F. Robustness of LSTM neural networks for multi-step forecasting of chaotic time series // Chaos, Solitons Fractals. – 2020. – Vol. 139. – No. 110045.